



UNIVERSIDAD
DE MURCIA



Facultad
de Biología

Informe tarea Explotación Semántica de Datos

Máster en Bioinformática

Facultad de Biología – Universidad de Murcia

Explotación semántica del grafo

cancer_therapy

Autor: Antonio José Manuel Martínez

Curso 2025-2026

Tabla de contenido

1. Introducción	3
2. Objetivos	3
2.1. Objetivo general	3
2.2. Objetivos específicos.....	4
3. Materiales	4
3.1. Herramientas y entorno	4
3.2. Recursos biomédicos y vocabularios reutilizados	4
4. Metodología	5
4.1. Modelado semántico del dominio	5
4.2. Construcción del grafo RDF en formato Turtle	6
4.3. Conversión a RDF/XML y carga en Blazegraph.....	7
4.4. Explotación del grafo mediante consultas SPARQL desde R	7
5. Resultados y discusión.....	8
5.1. Descripción general del grafo y evidencia de carga	8
5.2. Consulta 1: Integración fármaco–proteína–gen–enfermedad.....	9
5.3. Consulta 2: Análisis de mecanismos terapéuticos en cáncer de mama	10
5.4. Consulta 3: Número de fármacos disponibles por enfermedad	11
5.5. Consulta 4: Enfoque gen-céntrico en linfoma no Hodgkin.....	11
5.6. Consulta 5: Vista panorámica del grafo terapéutico	12
6. Conclusiones y líneas de trabajo futuro.....	14
6.1. Consideraciones finales y líneas de ampliación	14
7. Referencias.....	15
8. Ubicación de los recursos generados.....	15

1. Introducción

El crecimiento sostenido de fuentes biomédicas heterogéneas (bases de datos de fármacos, recursos de anotación proteica, catálogos de genes y ontologías clínicas) plantea un desafío recurrente en bioinformática: integrar conocimiento distribuido con semántica explícita y trazabilidad de las entidades. En este contexto, las tecnologías de la Web Semántica permiten representar información mediante grafos RDF, donde el conocimiento se expresa como tripletas (sujeto–predicado–objeto) y cada entidad se identifica mediante URIs resolubles y reutilizables. Este enfoque facilita la interoperabilidad entre recursos y la formulación de preguntas complejas mediante SPARQL, uno de los lenguajes fundamentales para la consulta de grafos RDF y bases de conocimiento semánticas.

En el ámbito oncológico, la integración semántica es especialmente relevante por la naturaleza multidimensional de la evidencia científica: un tratamiento farmacológico se vincula a una indicación clínica (enfermedad), a una diana molecular (proteína) y, a su vez, dicha diana se relaciona con su gen codificante y con asociaciones enfermedad–gen descritas en ontologías y recursos de referencia. Por ello, en este trabajo se construye un grafo RDF mínimo pero semánticamente expresivo, centrado en el dominio de terapias frente a cáncer, modelando explícitamente entidades de tipo **fármaco**, **proteína**, **gen** y **enfermedad**, así como relaciones terapéuticas y moleculares.

La práctica exige la creación de un grafo RDF propio, su almacenamiento en el triple store utilizado en clase, la reutilización de vocabularios biológicos externos y el diseño y ejecución de cinco consultas SPARQL mediante un script en R.

Con el objetivo de alinearse con estos requisitos, el grafo *cancer_therapy* se ha construido inicialmente en **Turtle**, reutilizando URIs de recursos biomédicos externos (p. ej., DrugBank, UniProt, Ensembl y MONDO), y posteriormente se ha convertido a **RDF/XML** utilizando la herramienta **EasyRDF**.

Finalmente, el grafo se ha cargado en **Blazegraph** dentro del servidor docente, en el namespace correspondiente, quedando disponible a través del endpoint SPARQL para su explotación mediante consultas desde R.

2. Objetivos

2.1. Objetivo general

El objetivo general de este trabajo es diseñar, construir y explotar un grafo de conocimiento RDF denominado *cancer_therapy*, integrando información terapéutica y biomolecular relacionada con el cáncer, y consultarlo mediante SPARQL desde R, cumpliendo los requisitos de la asignatura Explotación Semántica de Datos.

2.2. Objetivos específicos

- Modelar semánticamente el dominio de terapias oncológicas mediante entidades representativas de fármacos, proteínas, genes y enfermedades.
- Reutilizar vocabularios e identificadores biomédicos estándar, tales como DrugBank, UniProt, Ensembl y MONDO, para favorecer la interoperabilidad del grafo.
- Construir el dataset RDF en formato Turtle, asegurando consistencia semántica y correcta tipificación de las entidades.
- Convertir el grafo a formato RDF/XML mediante la herramienta EasyRDF y cargarlo en el triple store Blazegraph.
- Diseñar y ejecutar cinco consultas SPARQL con distintos niveles de complejidad, explotando las relaciones del grafo desde perspectivas clínicas, moleculares y analíticas.
- Documentar de forma detallada todo el proceso en un informe académico formal, incluyendo la interpretación de los resultados obtenidos.

3. Materiales

3.1. Herramientas y entorno

Para la construcción y explotación del grafo RDF se han utilizado las siguientes herramientas:

- **Formato de serialización RDF:** El grafo se ha definido inicialmente en formato Turtle, por su legibilidad y facilidad de edición. Posteriormente, se ha convertido a RDF/XML para facilitar su carga en el triple store.
- **Conversión de formatos:** Se ha empleado la herramienta EasyRDF para transformar el archivo Turtle a RDF/XML, siguiendo un flujo de trabajo similar al descrito en el ejemplo proporcionado en la asignatura.
- **Triple store:** El dataset RDF se ha cargado en el sistema Blazegraph, desplegado en el servidor docente de la asignatura, donde se ha creado el namespace correspondiente al grafo *cancer_therapy*.
- **Lenguaje y librerías:** Las consultas SPARQL se han ejecutado desde el lenguaje R, utilizando la librería SPARQL, que permite enviar consultas a un endpoint remoto y recuperar los resultados en forma de data frames.

3.2. Recursos biomédicos y vocabularios reutilizados

Con el fin de garantizar la interoperabilidad y reutilización del conocimiento, el grafo incorpora identificadores procedentes de recursos biomédicos ampliamente utilizados:

- **MONDO** para la representación de enfermedades.
- **DrugBank** para la identificación de fármacos.
- **UniProt** para proteínas.
- **Ensembl** para genes.

Se ha utilizado el **Biolink Model**, un estándar de interconexión de datos biomédicos que facilita la representación de las relaciones entre genes, proteínas, enfermedades y fármacos.

4. Metodología

En este apartado se describe de manera detallada la metodología seguida para la construcción, conversión, carga y explotación del grafo RDF *cancer_therapy*. El proceso adoptado sigue un flujo de trabajo estructurado y reproducible, alineado con los principios de la Web Semántica.

La metodología se ha organizado en cuatro fases principales: (i) modelado semántico del dominio, (ii) construcción del grafo en Turtle, (iii) conversión a RDF/XML y carga en el triple store Blazegraph, y (iv) explotación del grafo mediante consultas SPARQL ejecutadas desde R.

4.1. Modelado semántico del dominio

El primer paso del trabajo consistió en el diseño del modelo semántico que sustenta el grafo *cancer_therapy*. Este modelo se ha centrado en representar de forma explícita las entidades y relaciones clave implicadas en el dominio de las terapias oncológicas, integrando información clínica y molecular en un único grafo de conocimiento.

Las entidades principales modeladas corresponden a cuatro clases fundamentales:

- **Fármacos**, como instancias de `ns0:Drug`, que constituyen los tratamientos terapéuticos empleados frente a distintos tipos de cáncer.
- **Proteínas**, como instancias de `ns0:Protein`, que actúan como dianas moleculares de los fármacos.
- **Genes**, como instancias de `ns0:Gene`, responsables de la codificación de las proteínas.
- **Enfermedades**, como instancias de `ns0:Disease`, correspondientes a patologías oncológicas.

Las relaciones semánticas definidas entre estas entidades reflejan interacciones biológicamente relevantes y permiten conectar distintos niveles de información. En concreto, se modelaron las siguientes propiedades:

- `ns0:treats`, que relaciona un fármaco con la enfermedad que trata.
- `ns0:binds` y `ns0:inhibits`, que describen el mecanismo de acción del fármaco sobre una proteína diana.
- `ns0:encodes`, que vincula un gen con la proteína que codifica.
- `ns0:associatedWith`, que representa asociaciones entre genes y enfermedades.

El diseño conceptual de estas clases y propiedades se ha inspirado en los principios del **Biolink Model**. Aunque el vocabulario no se ha importado directamente como ontología externa, su estructura conceptual ha guiado la definición del modelo, garantizando coherencia semántica e interoperabilidad con otros grafos biomédicos.

4.2. Construcción del grafo RDF en formato Turtle

Una vez definido el modelo semántico, se procedió a la construcción del grafo RDF en formato **Turtle**, seleccionado por su sintaxis compacta y legible. Este formato facilitó tanto la edición manual del grafo como la revisión de las tripletas generadas.

En el archivo Turtle se declararon explícitamente las clases y propiedades del vocabulario propio del proyecto, así como los prefijos necesarios para referenciar recursos biomédicos externos. Todas las entidades del grafo se identificaron mediante **URIs persistentes**, reutilizando identificadores de referencia siempre que fue posible. En la Figura 1 se muestran los prefijos declarados en el archivo Turtle del grafo *cancer_therapy*, que permiten identificar de forma inequívoca las entidades y vocabularios reutilizados.

```
@prefix rdf:      <http://www.w3.org/1999/02/22-rdf-syntax-ns#> .
@prefix rdfs:     <http://www.w3.org/2000/01/rdf-schema#> .
@prefix owl:    <http://www.w3.org/2002/07/owl#> .
@prefix biolink:  <https://w3id.org/biolink/vocab/> .
@prefix ensembl: <http://identifiers.org/ensembl/> .
@prefix uniprot:  <http://purl.uniprot.org/uniprot/> .
@prefix drugbank: <http://identifiers.org/drugbank/> .
@prefix mondo:   <http://purl.obolibrary.org/obo/MONDO_> .
@prefix ct:      <http://cancer_therapy.esd.es/> .
```

Figura 1. Prefijos RDF definidos en el archivo Turtle del grafo *cancer_therapy*, que permiten la reutilización de vocabularios estándar (RDF, RDFS, OWL), del modelo Biolink y de identificadores biomédicos (Ensembl, DrugBank y MONDO...), junto con el espacio de nombres propio del proyecto.

En particular, se emplearon los siguientes recursos externos:

- **DrugBank** para la identificación de fármacos: <http://identifiers.org/drugbank/>
- **UniProt** para proteínas: <http://purl.uniprot.org/uniprot/>
- **Ensembl** para genes: <http://identifiers.org/ensembl/>
- **MONDO** para enfermedades: http://purl.obolibrary.org/obo/MONDO_

Asimismo, se incluyeron etiquetas descriptivas mediante `rdfs:label` para todas las entidades, con el fin de facilitar la interpretación humana de los resultados obtenidos a partir de las consultas SPARQL. El grafo RDF resultante cumple con el tamaño mínimo exigido en la práctica y contiene un conjunto consistente de tripletas que representan tanto las entidades biomédicas como las relaciones terapéuticas y moleculares entre ellas.

```
drugbank:DB00073 rdf:type ct:Drug ;
  rdfs:label "Rituximab" ;
  ct:treats mondo:0018908 ;
  ct:binds uniprot:P11836 .

drugbank:DB00619 rdf:type ct:Drug ;
  rdfs:label "Imatinib" ;
  ct:treats mondo:0011996 ;
  ct:binds uniprot:P00519 .
```


Figura 2. Fragmento del archivo Turtle del grafo *cancer_therapy* que muestra la definición de fármacos oncológicos, sus etiquetas descriptivas y sus relaciones terapéuticas con enfermedades y proteínas diana.

4.3. Conversión a RDF/XML y carga en Blazegraph

Una vez finalizada la construcción del grafo en formato Turtle, se procedió a su conversión al formato **RDF/XML** mediante la herramienta **EasyRDF**, con el objetivo de facilitar su carga en el triple store. Este proceso de conversión preservó íntegramente la estructura del grafo, así como las URIs, clases y propiedades definidas en el modelo original.

El archivo RDF/XML resultante fue cargado en el sistema **Blazegraph**, desplegado en el servidor docente del Máster en Bioinformática. Para ello, se creó un namespace específico denominado *cancer_therapy*, dentro del cual quedó almacenado el grafo. Tras la carga, el dataset quedó accesible a través del siguiente endpoint SPARQL, que es el mismo que se usará para hacer las consultas en R:

http://dayhoff.inf.um.es:3042/blazegraph/namespace/cancer_therapy/sparql



The screenshot shows the Blazegraph workbench interface. At the top, there's a navigation bar with tabs: WELCOME, QUERY, UPDATE, EXPLORE, NAMESPACES (selected), STATUS, and PERFORMANCE. Below the navigation bar, the 'Namespaces' section is active, showing a table of namespaces. The 'cancer_therapy' namespace is selected, and its properties are displayed in a table below.

Property	Value
com.bigdata.relation.class	com.bigdata.rdf.store.LocalTripleStore
com.bigdata.rdf.sail.truthMaintenance	false
com.bigdata.rdf.store.AbstractTripleStore.textIndex	false
com.bigdata.rdf.store.AbstractTripleStore.justify	false
com.bigdata.namespace.cancer_therapy.spo.com.bigdata.btree.BTree.branchingFactor	1024
com.bigdata.rdf.store.AbstractTripleStore.statementIdentifiers	false
com.bigdata.relation.container	cancer_therapy
com.bigdata.rdf.store.AbstractTripleStore.axiomsClass	com.bigdata.rdf.axioms.NoAxioms
com.bigdata.rdf.sail.namespace	cancer_therapy
com.bigdata.rdf.store.AbstractTripleStore.quads	false
com.bigdata.rdf.store.AbstractTripleStore.geoSpatial	false
com.bigdata.relation.namespace	cancer_therapy
com.bigdata.journal.Journal.groupCommit	false
com.bigdata.rdf.store.AbstractTripleStore.vocabularyClass	com.bigdata.rdf.vocab.core.BigdataCoreVocabulary_v20160317
com.bigdata.namespace.cancer_therapy.lex.com.bigdata.btree.BTree.branchingFactor	400
com.bigdata.rdf.sail.isolateIndices	false

Figura 3. Visualización del namespace *cancer_therapy* y sus propiedades en el workbench de Blazegraph, confirmando la correcta carga y configuración del grafo RDF en el triple store.

Como resultado de este proceso, el grafo cargado en Blazegraph contiene un total de **104 triplas**, lo que confirma la correcta transformación y almacenamiento del dataset. La integridad del grafo se verificó mediante la ejecución de consultas SPARQL simples de prueba, comprobando que las entidades y relaciones definidas podían ser recuperadas correctamente.

4.4. Explotación del grafo mediante consultas SPARQL desde R

La fase final de la metodología consistió en la explotación del grafo RDF cargado en Blazegraph mediante consultas SPARQL ejecutadas desde el lenguaje **R**. Para ello, se desarrolló un script en R que establece la conexión con el endpoint SPARQL del namespace *cancer_therapy* y ejecuta de forma secuencial las consultas definidas.

Se diseñaron un total de **cinco consultas SPARQL**, cada una orientada a explotar el grafo desde una perspectiva distinta. Las consultas se ejecutaron utilizando la función `SPARQL()` de la librería homónima en R, recuperando los resultados en forma de data frames. Posteriormente, se realizaron pequeñas transformaciones sobre los resultados para mejorar su legibilidad, como la eliminación de caracteres propios de la representación de URIs (`<|>`).

Este enfoque permite automatizar completamente el proceso de consulta y análisis, facilitando la reproducibilidad del trabajo y demostrando la integración efectiva entre tecnologías de la Web Semántica y herramientas de análisis de datos propias del entorno bioinformático.

La metodología descrita proporciona un flujo de trabajo completo, reproducible y alineado con los principios de la Web Semántica, desde el modelado del dominio hasta la explotación del grafo mediante consultas SPARQL. En el siguiente apartado se presentan los resultados obtenidos a partir de las cinco consultas diseñadas y se discute su utilidad para la exploración del dominio terapéutico modelado.

5. Resultados y discusión

En este apartado se presentan y discuten los resultados obtenidos tras la ejecución de las cinco consultas SPARQL diseñadas sobre el grafo RDF *cancer_therapy*. El objetivo principal es evaluar si los resultados recuperados son coherentes con el modelo semántico propuesto y con el conocimiento biomédico esperado, así como analizar el valor añadido que aporta cada consulta en la explotación del grafo.

5.1. Descripción general del grafo y evidencia de carga

Tras la conversión del grafo RDF a formato RDF/XML y su posterior carga en el triple store Blazegraph en el siguiente enlace: <http://dayhoff.inf.um.es:3042/blazegraph>, el dataset *cancer_therapy* quedó correctamente almacenado en el namespace correspondiente y accesible mediante el endpoint SPARQL definido. La correcta carga del grafo se verificó tanto mediante la inspección del namespace en el entorno de administración de Blazegraph como mediante la ejecución de consultas SPARQL de prueba.

El grafo resultante contiene un total de **104 tripletas RDF**, lo que confirma que el dataset cumple con los requisitos mínimos de tamaño y que incluye un conjunto suficiente de entidades y relaciones para la formulación de consultas semánticas relativamente complejas. Estas tripletas representan tanto las entidades biomédicas principales (fármacos, proteínas, genes y enfermedades) como las relaciones terapéuticas y moleculares entre ellas.

La estructura del grafo permite recorrer distintos niveles de información, desde la relación clínica entre un fármaco y una enfermedad hasta las asociaciones moleculares subyacentes que implican proteínas diana y genes codificantes, lo que justifica el diseño de consultas con distintos grados de complejidad, que se explican a continuación.

5.2. Consulta 1: Integración fármaco–proteína–gen–enfermedad

“¿Qué fármacos oncológicos se unen (“bind”) a proteínas diana concretas, qué genes codifican dichas proteínas y con qué enfermedades están asociadas?”

La primera consulta tiene como objetivo recuperar cadenas completas de información que unan fármacos con sus proteínas diana, los genes que codifican dichas proteínas y las enfermedades asociadas a dichos genes. Esta consulta explota el grafo en toda su profundidad semántica, integrando información terapéutica, molecular y clínica en una única consulta.

Cabe destacar que la consulta se restringe explícitamente a interacciones de tipo **binds**, lo que permite analizar únicamente fármacos que se unen directamente a proteínas diana.

```
PREFIX rdfs: <http://www.w3.org/2000/01/rdf-schema#>
PREFIX ns0: <http://cancer_therapy.esd.es/>
PREFIX mondo: <http://purl.obolibrary.org/obo/MONDO_>

SELECT
  ?drug ?drugLabel ?protein ?proteinLabel ?gene ?geneLabel ?disease ?diseaseLabel
WHERE {
  ?drug a ns0:Drug ;
    rdfs:label ?drugLabel ;
    ns0:binds ?protein .

  ?protein rdfs:label ?proteinLabel .

  ?gene a ns0:Gene ;
    rdfs:label ?geneLabel ;
    ns0:encodes ?protein ;
    ns0:associatedWith ?disease .

  ?disease a ns0:Disease ;
    rdfs:label ?diseaseLabel .
}
```

	drug	drugLabel	protein	proteinLabel
1	http://identifiers.org/drugbank/DB00072	Trastuzumab	http://purl.uniprot.org/uniprot/P04626	HER2
2	http://identifiers.org/drugbank/DB00530	Erlotinib	http://purl.uniprot.org/uniprot/P00533	EGFR
3	http://identifiers.org/drugbank/DB00619	Imatinib	http://purl.uniprot.org/uniprot/P00519	ABL1
4	http://identifiers.org/drugbank/DB00073	Rituximab	http://purl.uniprot.org/uniprot/P11836	CD20

	gene	geneLabel	disease	diseaseLabel
http://identifiers.org/ensembl/ENSG00000141736	ERBB2	http://purl.obolibrary.org/obo/MONDO_0004989	Breast cancer	
http://identifiers.org/ensembl/ENSG00000146648	EGFR	http://purl.obolibrary.org/obo/MONDO_0005233	Non-small cell lung carcinoma	
http://identifiers.org/ensembl/ENSG00000097007	ABL1	http://purl.obolibrary.org/obo/MONDO_0011996	Chronic myeloid leukemia	
http://identifiers.org/ensembl/ENSG00000156738	MS4A1	http://purl.obolibrary.org/obo/MONDO_0018908	Non-Hodgkin lymphoma	

Figura 4. Consulta 1 – Código SPARQL (arriba) y resultados de la salida de la consulta en R (abajo).

Los resultados son plenamente coherentes con el conocimiento biomédico esperado y validan la correcta representación de las relaciones semánticas en el grafo. Cada fila representa una cadena completa que conecta un fármaco con su diana molecular, el gen codificante y la enfermedad asociada.

Por ejemplo, Trastuzumab aparece correctamente asociado a la proteína HER2, codificada por el gen *ERBB2*, y vinculada a cáncer de mama. De forma análoga, Erlotinib se relaciona con EGFR y cáncer de pulmón no microcítico, mientras que Imatinib aparece asociado a ABL1 y leucemia mieloide crónica.

Es relevante señalar que tratamientos como **Olaparib no aparecen en esta consulta**, lo cual es un resultado esperado. En el grafo *cancer_therapy*, Olaparib se modela exclusivamente mediante relaciones de tipo **inhibits**, por lo que su exclusión confirma tanto la coherencia del modelo como el correcto funcionamiento de la consulta.

5.3. Consulta 2: Análisis de mecanismos terapéuticos en cáncer de mama

“¿Qué fármacos se utilizan para tratar el cáncer de mama y cuál es su mecanismo de acción sobre las proteínas diana (unión o inhibición)?”

La segunda consulta se centra en una enfermedad concreta, el **cáncer de mama**, con el objetivo de identificar los fármacos que la tratan y caracterizar su mecanismo de acción sobre proteínas diana, diferenciando entre interacciones de tipo unión (**binds**) e inhibición (**inhibits**).

```
PREFIX rdfs: <http://www.w3.org/2000/01/rdf-schema#>
PREFIX ns0: <http://cancer_therapy.esd.es/>
PREFIX mondo: <http://purl.obolibrary.org/obo/MONDO_>

SELECT ?diseaseLabel ?drug ?drugLabel ?interaction ?protein ?proteinLabel
WHERE {
  ?drug a ns0:Drug ; rdfs:label ?drugLabel ; ns0:treats mondo:0004989 .
  mondo:0004989 rdfs:label ?diseaseLabel .

  {
    ?drug ns0:binds ?protein .
    BIND("binds" AS ?interaction)
  }
  UNION
  {
    ?drug ns0:inhibits ?protein .
    BIND("inhibits" AS ?interaction)
  }
  ?protein rdfs:label ?proteinLabel .
}
```

diseaseLabel	drug	drugLabel
1 Breast cancer	http://identifiers.org/drugbank/DB00072	Trastuzumab
2 Breast cancer	http://identifiers.org/drugbank/DB09074	Olaparib
3 Breast cancer	http://identifiers.org/drugbank/DB09074	Olaparib

interaction	protein	proteinLabel
binds	http://purl.uniprot.org/uniprot/P04626	HER2
inhibits	http://purl.uniprot.org/uniprot/P09874	PARP1
inhibits	http://purl.uniprot.org/uniprot/Q9UGN5	PARP2

Figura 5. Consulta 2 – Código SPARQL (arriba) y resultados de la salida de la consulta en R (abajo).

Los resultados reflejan correctamente la heterogeneidad de mecanismos terapéuticos empleados en el tratamiento del cáncer de mama. **Trastuzumab** aparece asociado a una interacción de tipo **unión** con HER2, mientras que **Olaparib** aparece dos veces debido a su capacidad para **inhibir** dos proteínas distintas (PARP1 y PARP2).

La duplicación de Olaparib en los resultados no representa un error, sino que es consecuencia directa del modelo semántico, donde cada interacción fármaco–proteína se representa explícitamente como una tripleta independiente. Este comportamiento demuestra la capacidad del grafo para representar fármacos con múltiples dianas moleculares y para recuperar esta información de forma explícita mediante SPARQL.

5.4. Consulta 3: Número de fármacos disponibles por enfermedad

“¿Cuántos fármacos distintos están asociados al tratamiento de cada enfermedad representada en el grafo?”

La tercera consulta adopta un enfoque agregado, con el objetivo de calcular el número de fármacos distintos asociados al tratamiento de cada enfermedad presente en el grafo. Para ello, se emplea una agregación mediante **COUNT(DISTINCT ?drug)**.

```
PREFIX rdfs: <http://www.w3.org/2000/01/rdf-schema#>
PREFIX ns0: <http://cancer_therapy.esd.es/>

SELECT ?disease ?diseaseLabel (COUNT(DISTINCT ?drug) AS ?numDrugs)
WHERE {
  ?drug a ns0:Drug ;
        ns0:treats ?disease .
  ?disease a ns0:Disease ;
           rdfs:label ?diseaseLabel .
}

GROUP BY ?disease ?diseaseLabel
ORDER BY DESC(?numDrugs) ?diseaseLabel
```

	disease	diseaseLabel	numDrugs
1	http://purl.obolibrary.org/obo/MONDO_0004989	Breast cancer	2
2	http://purl.obolibrary.org/obo/MONDO_0011996	Chronic myeloid leukemia	1
3	http://purl.obolibrary.org/obo/MONDO_0018908	Non-Hodgkin lymphoma	1
4	http://purl.obolibrary.org/obo/MONDO_0005233	Non-small cell lung carcinoma	1

Figura 6. Consulta 3 – Código SPARQL (arriba) y resultados de la salida de la consulta en R (abajo).

Los resultados muestran que el cáncer de mama es la enfermedad con mayor número de tratamientos representados en el grafo, mientras que el resto de patologías cuentan con un único fármaco asociado. Este resultado es coherente con la estructura del dataset y demuestra la utilidad de las consultas agregadas para obtener una visión global de la **cobertura terapéutica** modelada. Esta consulta incrementa su importancia conforme mayor es el número de tripletas que tuviera el grafo, ya que permite estimar la cobertura terapéutica asociada a cada enfermedad en función del número de fármacos representados en el grafo. (cuantas más tripletas disease/drugs más grande será el resultado).

5.5. Consulta 4: Enfoque gen-céntrico en linfoma no Hodgkin

“¿Qué genes están asociados al linfoma no Hodgkin, qué proteínas codifican y qué fármacos actúan sobre dichas proteínas?”

La cuarta consulta adopta un **enfoque gen-céntrico**, en el sentido de que el **gen constituye la entidad central del análisis**. A partir de una enfermedad concreta (linfoma no Hodgkin), la consulta identifica los genes asociados a dicha patología y explora, desde estos genes, las proteínas que codifican y los fármacos que actúan sobre dichas proteínas, integrando así información genética, molecular y terapéutica.

De este modo, la consulta muestra la capacidad del grafo RDF *cancer_therapy* para integrar información genética, molecular y clínica, y demuestra cómo un enfoque centrado en genes puede facilitar la identificación de tratamientos relevantes a partir de asociaciones gen-enfermedad.

```

PREFIX rdfs: <http://www.w3.org/2000/01/rdf-schema#>
PREFIX ns0: <http://cancer_therapy.esd.es/>
PREFIX mondo: <http://purl.obolibrary.org/obo/MONDO_>

SELECT DISTINCT
  ?diseaseLabel ?gene ?geneLabel ?protein ?proteinLabel ?drug ?drugLabel
WHERE {

  BIND(mondo:0018908 AS ?disease)
  ?disease rdfs:label ?diseaseLabel .

  ?gene a ns0:Gene ; rdfs:label ?geneLabel ;
    ns0:associatedWith ?disease ;
    ns0:encodes ?protein .

  ?protein rdfs:label ?proteinLabel .

  ?drug a ns0:Drug ; rdfs:label ?drugLabel .
  { ?drug ns0:binds ?protein . }
  UNION
  { ?drug ns0:inhibits ?protein . }
}

```

```

          diseaseLabel                                     gene geneLabel
1 Non-Hodgkin lymphoma http://identifiers.org/ensembl/ENSG00000156738      MS4A1
                                protein proteinLabel
http://purl.uniprot.org/uniprot/P11836      CD20
                                drug drugLabel
http://identifiers.org/drugbank/DB00073 Rituximab

```

Figura 7. Consulta 4 – Código SPARQL (arriba) y resultados de la salida de la consulta en R (abajo).

El resultado obtenido es coherente con el conocimiento biomédico, ya que el Rituximab es un anticuerpo monoclonal dirigido contra CD20, proteína codificada por el gen *MS4A1*, ampliamente utilizada en el tratamiento del linfoma no Hodgkin. Esta consulta demuestra la capacidad del grafo para integrar asociaciones **gen–enfermedad** con información terapéutica.

Asimismo, la consulta ilustra cómo la integración de información procedente de recursos biomédicos heterogéneos facilita la formulación de preguntas complejas que no podrían resolverse fácilmente mediante bases de datos relacionales tradicionales. La capacidad de recorrer el grafo desde la enfermedad hasta el tratamiento, pasando por genes y proteínas intermedias, demuestra el valor añadido de los grafos RDF como herramienta para la exploración y el análisis del conocimiento biomédico estructurado.

5.6. Consulta 5: Vista panorámica del grafo terapéutico

“¿Qué relaciones existen entre enfermedades y fármacos en el grafo y, cuando es posible, qué proteínas diana y genes están implicados?”

La quinta consulta proporciona una vista global del grafo *cancer_therapy*, recuperando todas las relaciones **fármaco–enfermedad** y, cuando está disponible, la información asociada sobre proteínas diana y genes codificantes.

Desde el punto de vista de la explotación semántica, esta consulta resulta especialmente útil para obtener una visión de conjunto del conocimiento representado en el grafo, identificar patrones generales y detectar posibles ampliaciones futuras del dataset, como la incorporación de nuevos fármacos, enfermedades o relaciones moleculares.

```

PREFIX rdfs: <http://www.w3.org/2000/01/rdf-schema#>
PREFIX ns0: <http://cancer_therapy.esd.es/>
PREFIX mondo: <http://purl.obolibrary.org/obo/MONDO_>

SELECT DISTINCT
  ?disease ?diseaseLabel ?drug ?drugLabel ?protein ?proteinLabel ?gene ?geneLabel
WHERE {
  ?drug a ns0:Drug ; rdfs:label ?drugLabel ; ns0:treats ?disease .

  ?disease a ns0:Disease ; rdfs:label ?diseaseLabel .

  OPTIONAL {
    { ?drug ns0:binds ?protein . }
    UNION
    { ?drug ns0:inhibits ?protein . }

    ?protein rdfs:label ?proteinLabel .

    ?gene a ns0:Gene ; rdfs:label ?geneLabel ; ns0:encodes ?protein .
  }
}
ORDER BY ?diseaseLabel ?drugLabel ?proteinLabel

```

	disease	diseaseLabel	drug	drugLabel
1	http://purl.obolibrary.org/obo/MONDO_0004989	Breast cancer	http://identifiers.org/drugbank/DB09074	olaparib
2	http://purl.obolibrary.org/obo/MONDO_0004989	Breast cancer	http://identifiers.org/drugbank/DB09074	olaparib
3	http://purl.obolibrary.org/obo/MONDO_0004989	Breast cancer	http://identifiers.org/drugbank/DB00072	Trastuzumab
4	http://purl.obolibrary.org/obo/MONDO_0011996	Chronic myeloid leukemia	http://identifiers.org/drugbank/DB00619	Imatinib
5	http://purl.obolibrary.org/obo/MONDO_0018908	Non-Hodgkin lymphoma	http://identifiers.org/drugbank/DB00073	Rituximab
6	http://purl.obolibrary.org/obo/MONDO_0005233	Non-small cell lung carcinoma	http://identifiers.org/drugbank/DB00530	Erlotinib
	protein	proteinLabel	gene	geneLabel
1	http://purl.uniprot.org/uniprot/P09874	PARP1	http://identifiers.org/ensembl/ENSG00000171862	PARP1
2	http://purl.uniprot.org/uniprot/Q9UGN5	PARP2	http://identifiers.org/ensembl/ENSG00000128050	PARP2
3	http://purl.uniprot.org/uniprot/P04626	HER2	http://identifiers.org/ensembl/ENSG00000141736	ERBB2
4	http://purl.uniprot.org/uniprot/P00519	ABL1	http://identifiers.org/ensembl/ENSG00000097007	ABL1
5	http://purl.uniprot.org/uniprot/P11836	CD20	http://identifiers.org/ensembl/ENSG00000156738	MS4A1
6	http://purl.uniprot.org/uniprot/P00533	EGFR	http://identifiers.org/ensembl/ENSG00000146648	EGFR

Figura 8. Consulta 5 – Código SPARQL (arriba) y resultados de la salida de la consulta en R (abajo).

Los resultados muestran que cada enfermedad está asociada a uno o varios fármacos específicos, y que estos, a su vez, se relacionan con proteínas diana claramente definidas dentro del modelo. En el caso del cáncer de mama, se observa la coexistencia de distintos mecanismos terapéuticos, como la inhibición de PARP1 y PARP2 por Olaparib y la unión de Trastuzumab a HER2, lo que refleja de manera adecuada la diversidad de enfoques farmacológicos empleados en el tratamiento de esta patología y la complejidad biológica subyacente.

Para el resto de enfermedades representadas en el grafo, los resultados ponen de manifiesto asociaciones directas y bien definidas entre un fármaco, su proteína diana y el gen correspondiente, como ocurre con Imatinib y ABL1 en la leucemia mieloide crónica, Rituximab y CD20 en el linfoma no Hodgkin, o Erlotinib y EGFR en el cáncer de pulmón no microcítico. La claridad de estas relaciones facilita la interpretación de los resultados y confirma que el modelo semántico captura de forma correcta las conexiones fundamentales entre los distintos niveles de información biomédica.

En conjunto, esta consulta demuestra la capacidad del grafo RDF *cancer_therapy* para integrar información clínica y molecular en una estructura única y navegable, permitiendo recorrer el conocimiento desde la enfermedad hasta las dianas terapéuticas implicadas. Asimismo, pone de manifiesto el valor de las consultas SPARQL que incorporan patrones opcionales para ofrecer una visión global del conocimiento representado, manteniendo la coherencia semántica incluso cuando el nivel de detalle molecular disponible varía entre las distintas entidades.

6. Conclusiones y líneas de trabajo futuro

En este trabajo se ha llevado a cabo el diseño, construcción y explotación de un grafo de conocimiento RDF denominado *cancer_therapy*, orientado a la integración de información terapéutica y biomolecular en el ámbito del cáncer. A través de la utilización de tecnologías de la Web Semántica, se ha demostrado que es posible representar de forma estructurada y coherente relaciones complejas entre fármacos, proteínas, genes y enfermedades, facilitando la interoperabilidad y la trazabilidad del conocimiento biomédico.

El modelo semántico propuesto, inspirado en los principios del Biolink Model y basado en la reutilización de identificadores estándar procedentes de recursos biomédicos de referencia (DrugBank, UniProt, Ensembl y MONDO), ha permitido construir un grafo consistente y semánticamente expresivo. La correcta carga del dataset en el triple store Blazegraph y su posterior explotación mediante consultas SPARQL ejecutadas desde R confirman la viabilidad del flujo de trabajo adoptado y la integración efectiva entre tecnologías semánticas y herramientas propias del análisis bioinformático.

Los resultados obtenidos a partir de las cinco consultas SPARQL diseñadas muestran que el grafo *cancer_therapy* es capaz de responder a preguntas con distintos niveles de complejidad, desde consultas moleculares específicas hasta análisis agregados y vistas panorámicas del conocimiento representado. La coherencia de los resultados con el conocimiento biomédico establecido valida tanto el modelo de datos como las relaciones semánticas definidas, y pone de manifiesto el valor de los grafos RDF para la exploración del dominio terapéutico oncológico.

Desde una perspectiva formativa, este trabajo ha permitido consolidar conceptos fundamentales relacionados con la Explotación Semántica de Datos y su aplicación al ámbito biomédico, tales como el uso de grafos RDF, la definición de modelos semánticos coherentes y la formulación de consultas SPARQL para la explotación de conocimiento estructurado. En este sentido, el grafo *cancer_therapy* constituye un ejemplo práctico de cómo estas tecnologías pueden emplearse para integrar y analizar información compleja de forma sistemática y reproducible.

6.1. Consideraciones finales y líneas de ampliación

A pesar de los resultados obtenidos, este trabajo presenta algunas limitaciones derivadas principalmente del tamaño y alcance del dataset, que se ha restringido a un conjunto reducido de enfermedades y tratamientos con fines académicos. Asimismo, aunque el diseño del modelo se ha inspirado en Biolink, no se ha incorporado explícitamente dicha ontología como vocabulario formal, lo que limita el uso de razonamiento automático e inferencia semántica.

Como líneas de trabajo futuro, sería de interés ampliar el grafo incorporando un mayor número de fármacos, enfermedades y relaciones moleculares, así como integrar de forma explícita ontologías biomédicas estándar para enriquecer el modelo semántico. Adicionalmente, la aplicación de técnicas de inferencia y la interconexión con otros grafos de conocimiento biomédico permitirían explotar todo el potencial del enfoque semántico presentado, consolidando el grafo *cancer_therapy* como una base sólida para análisis más complejos en el ámbito de la bioinformática.

7. Referencias

- World Wide Web Consortium (W3C). (2014). *RDF 1.1 Turtle*. <https://www.w3.org/TR/turtle/>
- World Wide Web Consortium (W3C). (2014). *RDF 1.1 concepts and abstract syntax*. <https://www.w3.org/TR/rdf11-concepts/>
- World Wide Web Consortium (W3C). (2013). *SPARQL 1.1 query language*. <https://www.w3.org/TR/sparql11-query/>
- Ashburner, M., Ball, C. A., Blake, J. A., Botstein, D., Butler, H., Cherry, J. M., ... Sherlock, G. (2000). Gene ontology: Tool for the unification of biology. *Nature Genetics*, 25(1), 25–29. <https://doi.org/10.1038/75556>
- Wishart, D. S., Feunang, Y. D., Guo, A. C., Lo, E. J., Marcu, A., Grant, J. R., ... Wilson, M. (2018). DrugBank 5.0: A major update to the DrugBank database for 2018. *Nucleic Acids Research*, 46(D1), D1074–D1082. <https://doi.org/10.1093/nar/gkx1037>
- The UniProt Consortium. (2023). UniProt: The universal protein knowledgebase in 2023. *Nucleic Acids Research*, 51(D1), D523–D531. <https://doi.org/10.1093/nar/gkac1052>
- Köhler, S., Gargano, M., Matentzoglou, N., Carmody, L. C., Lewis-Smith, D., Vasilevsky, N. A., ... Robinson, P. N. (2021). The Human Phenotype Ontology in 2021. *Nucleic Acids Research*, 49(D1), D1207–D1217. <https://doi.org/10.1093/nar/gkaa1043>
- Hu, Y., Vinayagam, A., Nand, A., Comjean, A., Chung, V., Hao, T., ... Mohr, S. E. (2018). Molecular interaction search tool (MIST): An integrated resource for mining gene and protein interaction data. *Nucleic Acids Research*, 46(D1), D567–D574. <https://doi.org/10.1093/nar/gkx1116>
- Jupp, S., Malone, J., Bolleman, J., Brandizi, M., Davies, M., Garcia, L., ... Parkinson, H. (2014). The EBI RDF platform: Linked open data for the life sciences. *Bioinformatics*, 30(9), 1338–1339. <https://doi.org/10.1093/bioinformatics/btt765>

8. Ubicación de los recursos generados

A continuación, se indican las ubicaciones donde se encuentran los recursos creados y utilizados en el desarrollo de esta tarea:

- **Repositorio GitHub del proyecto**
https://github.com/AntonioJoseManuelMartinez/ESD_tarea
- **Servidor Dayhoff del Máster:**
/home/alumno14/Master/E.S.D/Practica_entregable
- **Puerto del Blazegraph:**
<http://dayhoff.inf.um.es:3042/blazegraph>